

Whalespray

Agente de Atencion Inteligente

Informe de arquitectura, costes y comparativa

Elaborado por: Orchids AI Platform
Julio 2026

1. Resumen del Agente

El agente Whalespray es un asistente tecnico-comercial inteligente especializado en productos quimicos industriales (aerosoles, lubricantes, limpiadores y tratamientos tecnicos). Su funcion es asesorar a clientes y al equipo de ventas sobre el uso, aplicaciones y beneficios del catalogo de Whalespray.

Modelo de IA

El agente utiliza el modelo LLaMA 3.3 70B, creado por Meta, ejecutado a traves de la infraestructura de Groq. Groq utiliza chips especializados llamados LPU (Language Processing Units) que permiten respuestas muy rapidas a bajo coste.

- LLaMA 3.3 70B = el 'cerebro' (modelo de IA de Meta)
- Groq = la plataforma que lo ejecuta a alta velocidad

En el entorno de desarrollo (Orchids) se utiliza Claude Haiku de Anthropic como alternativa. El agente siempre responde en el idioma del usuario (espanol o ingles) y se basa exclusivamente en la informacion de los documentos cargados (RAG).

Motor de conocimiento (RAG)

El sistema utiliza busqueda hibrida: combina busqueda semantica con ChromaDB (vectores) y busqueda por palabras clave con BM25. Los resultados se fusionan mediante Reciprocal Rank Fusion con una ponderacion de 60% semantico y 40% de palabras clave.

2. Arquitectura Tecnica

Componentes principales

- Frontend: React + Vite + Tailwind CSS (desplegado en Vercel)
- Backend: FastAPI + Uvicorn (desplegado en Railway)
- RAG Engine: ChromaDB (vectores) + BM25 (busqueda hibrida)
- Base de datos: SQLite (conversaciones, contactos, fuentes de datos)
- LLM Provider: Groq (LLaMA 3.3 70B) con fallback a Anthropic Claude
- Almacenamiento persistente: Railway Volume
- Panel de administracion con proteccion por contrasena

Flujo de una consulta

1. El usuario envia un mensaje desde el chat web
2. Se recupera el historial de la conversacion (ultimos 10 mensajes)
3. El RAG Engine busca en los documentos indexados (semantica + palabras clave)
4. Se construye el prompt con: instrucciones del sistema + memoria + contexto RAG
5. Se llama a LLaMA 3.3 a traves de la API de Groq
6. Se guarda la respuesta y se devuelve al usuario con fuentes y tarjetas de producto

Despliegue

Entorno	Frontend	Backend	Modelo IA
Desarrollo	Orchids	Uvicorn local	Claude (Anthropic)
Produccion	Vercel	Railway	LLaMA 3.3 (Groq)

3. Desglose de Costes Mensuales

3.1 Infraestructura Fija

Concepto	Coste	Notas
Railway (backend + BD)	\$5/mes	Servidor, SQLite, ChromaDB
Vercel (frontend)	Gratis	Hosting estatico
Total fijo	\$5/mes	

3.2 Coste Variable (LLM)

Modelo LLaMA 3.3 70B ejecutado en Groq:

Concepto	Precio
Precio input	\$0,59 / 1M tokens
Precio output	\$0,79 / 1M tokens
Coste por mensaje tipico	~\$0,0006
1.000 chats/mes	~\$0,60
10.000 chats/mes	~\$6,00

3.3 Coste Total Estimado

Escenario	Chats/mes	Coste total
Bajo	100	~\$5,06
Medio	1.000	~\$5,60
Alto	10.000	~\$11,00

4. Comparativa con Google Agent Platform

Aspecto	Whalespray (actual)	Google Agent Platform
Coste base	~\$5/mes	\$0 (sin agentes)
Coste 10.000 chats	~\$11	~\$20 - \$70
Coste 100.000 chats	~\$65	~\$200 - \$700
RAG / Documentos	Incluido (ChromaDB)	Incluido (Vertex AI)
WhatsApp nativo	Manual (WAHA)	Integracion directa
Panel admin	A medida	Dashboard GCP
Escalabilidad	Manual (Railway)	Automatica (Google)
Personalizacion	Total (codigo abierto)	Limitado a plantillas
Latencia	~1-3s (Groq)	~2-5s
Licencia	Codigo 100% tuyo	Atado a Google Cloud

5. Conclusion

El agente Whalespray es significativamente mas economico (entre 3 y 10 veces) que Google Agent Platform para volumenenes de conversacion bajos y medios (hasta 10.000 chats al mes).

- Google Agent Platform es recomendable cuando se necesitan mas de 100.000 conversaciones al mes o se requiere integracion WhatsApp oficial sin configuracion adicional.
- La principal ventaja del agente Whalespray es que el codigo es 100% propiedad del cliente, sin dependencia de ningun proveedor externo, lo que permite total libertad de personalizacion y modificacion.
- Groq ofrece la mejor relacion calidad-precio para modelos LLM del mercado, con tiempos de respuesta de 1-3 segundos gracias a sus chips LPU especializados.
- El agente puede ampliarse facilmente con nuevas funcionalidades al ser codigo abierto y estar construido sobre tecnologias estandar (Python, React, FastAPI).